

Abbildung 4.6 verdeutlicht eine solche Struktur. In dem dargestellten Modell gibt es zwei substanziell definierte Faktoren zweiter Ordnung (F3 und F6) deren jeweils sechs Indikatoren in zwei Gruppen aufgeteilt werden (mit je positiv und negativ formulierten Items), denen jeweils zwei separate Faktoren erster Ordnung zugeordnet werden (F1/F2 und F4/F5).

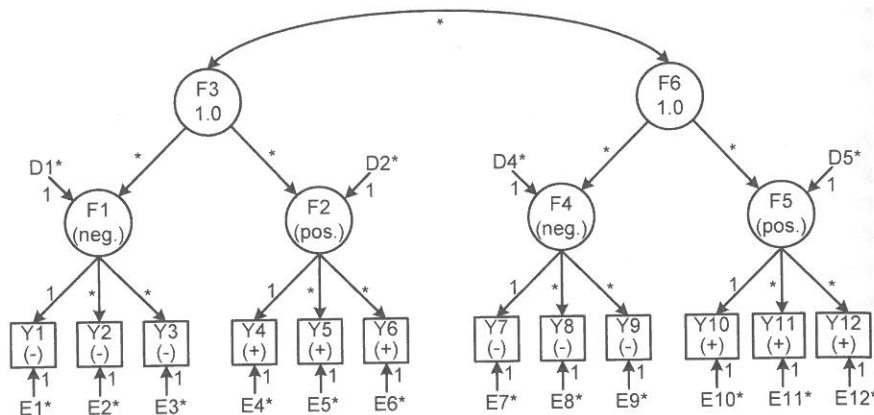


Abbildung 4.6: Messmodell zweiter Ordnung mit zwei substanziell bestimmten Faktoren zweiter Ordnung (F3 und F6) und mit jeweils zwei methoden-induzierten Faktoren erster Ordnung (F1/F2 und F4/F5)

## 5 Spezielle Varianten der SEM-Analyse

### 5.1 Welche SE-Modelle können zur Längsschnittanalyse mit Paneldaten eingesetzt werden?

Für SEM-Längsschnittanalysen mit Paneldaten stehen eine Vielzahl von unterschiedlichen SE-Modelltypen zur Verfügung. Im Folgenden werden nur einige wenige dieser Modelle in äußerst knapper Form vorgestellt.<sup>1</sup> Zusätzlich wird in einem eigenständigen Kapitel ein immer beliebter werdendes SE-Längsschnittmodell, das sogenannte "latente Wachstumskurvenmodell" (a.a.O.), etwas ausführlicher erläutert.

In all diesen Modellierungen ist zu berücksichtigen, dass Längsschnittanalysen, bei denen Mehr-Indikatoren-Messmodelle benutzt werden sollen, immer sicherstellen müssen, dass die Faktorstrukturen der Messmodelle über die Zeit hinweg konstant bleiben. Hinweise dazu werden im folgenden Kapitel 5.1.2 "Faktorinvarianz in SEM-Längsschnittanalysen/ Gruppenvergleichen" gegeben.

#### ad: Autoregressive Modelle (n-ter Ordnung)

Autoregressive Modelle werden auch als "Quasi-Simplex-Modelle" oder "Markov-Simplex-Modelle" bezeichnet. Mit diesen Modellen können zeitliche Veränderungen von Faktoren in einem Ein-Indikator- oder einem Mehr-Indikatoren-Messmodell analysiert werden. Dabei führen die autoregressiven Modelle die Veränderungen in den Faktorwerten zu einem Zeitpunkt  $t$  auf Einflüsse der davor liegenden Werte des gleichen Faktors zum Zeitpunkt  $t-1$  zurück. Jeder Faktor wird nur vom unmittelbar vorausgehenden Faktor und keinem weiteren Faktor beeinflusst. Da aber jeder abhängige Faktor auch noch von einer Residualgröße bestimmt wird, handelt es sich um "Quasi"-Simplex-Modelle und um keine reinen Simplex-Modelle.

Zusätzlich können auch noch verschiedene Varianten von autoregressiven Modellen unterschieden werden. So ist es z.B. möglich, eine Abhängigkeitsstruktur zwischen den zeitspezifischen Zufallsmessfehlern oder den Faktorfehlern zu spezifizieren. Durch die Spezifikation von Korrelationen zwischen den

<sup>1</sup> Vgl. ausführlicher: Biesanz 2012; Sivo 2001; Sivo/Willson 2000.

Messfehlern desselben Indikators über die Zeit hinweg (sog. "diachrone Messfehlerkorrelationen", a.a.O.) kann auch Autokorrelation berücksichtigt und deren Ausmaß ermittelt werden (gemessen an der Höhe der geschätzten Korrelationen). Alternativ dazu kann auch eine Kausalstruktur zwischen den Residuen (anstatt Korrelationen) modelliert werden (z.B. "moving average"-Modelle oder autoregressive "moving-average"-Modelle). Bei diesen Modellen wird ein Messfehler zum Messzeitpunkt  $t$  in kausaler Abhängigkeit von Messfehlern vorhergehender Zeitpunkte (z.B.:  $t-1$ ) modelliert.<sup>2</sup>

Handelt es sich bei den analysierten Effekten stets um solche Einflüsse, die ihren Ursprung zum Zeitpunkt  $t-1$  genommen haben, dann sind die Modelle von 1-ter Ordnung. Werden auch weiter zurückliegende Effektquellen zugelassen, erhöht sich der Ordnungswert des Modells (bei  $t-2$  erhält man ein Modell 2. Ordnung bei; bei  $t-3$  von 3. Ordnung usw.). Direkte Effekte in Modellen höherer Ordnung, die über mehrere Zeitabschnitte hinweg reichen und dabei einen oder mehrere Messzeitpunkte überspringen, wie z.B. ein direkter Effekt von  $F(t1)$  auf  $F(t3)$ , werden auch "schlafende Effekte" genannt, da sie niemals zum nächst möglichen Zeitpunkt (hier:  $t2$ ) sondern immer erst mit (teilweise beträchtlicher) Zeitverzögerung wirken.

Ein Spezialfall autoregressiver Modelle sind sog. kreuzverzögerte Autoregressionsmodelle (cross-lagged autoregressive models). Abbildung 5.1 zeigt beispielhaft ein solches latentes cross-lagged autoregressives Modell mit zwei Faktoren über drei Zeitpunkte hinweg, das auch diachrone Messfehlerkorrelationen (a.a.O.) aufweist.

Mit Hilfe solcher Modelle lassen sich wichtige Fragen bei Tests der kausalen Relation zwischen theoretischen Konstrukten beantworten. Es lässt sich damit z.B. abklären, ob Autoritarismus ( $F1$ ) zu Ausländerfeindlichkeit ( $F2$ ) führt, oder ob diese Wirkungskette eher umzudrehen ist. Das abgebildete Modell kann dazu beitragen, solche Fragen zu beantworten: Sollte die "wahre" Kausalstruktur  $F1 \rightarrow F2$  lauten, so dürften sich nur für diese Relation statistisch signifikante Effekte vorfinden lassen, und für die umgekehrte Richtung  $F2 \rightarrow F1$  sollten dann keine signifikanten Effekte auftreten. Gleichzeitig kontrolliert das Modell autoregressive Kausaleffekte desselben Konstrukts über die Zeit hinweg, also z.B. die Kausaleffekte  $F1(t1) \rightarrow F1(t2) \rightarrow F1(t3)$ . Daher eignen sich kreuzverzögerte Autoregressionsmodelle ideal zur Modellierung von kausalen Längsschnittanalysen.

Vorsicht ist jedoch bei der Interpretation von autoregressiven Effekten eines Faktors über die Zeit hinweg geboten. Denn diese Effekte sind nicht im klassi-

schen Sinne als Pfadkoeffizienten sondern nur als Stabilitätskoeffizienten (a.a.O.) zu interpretieren. Geschieht dies nicht, entstehen unzulässige Schlussfolgerungen.

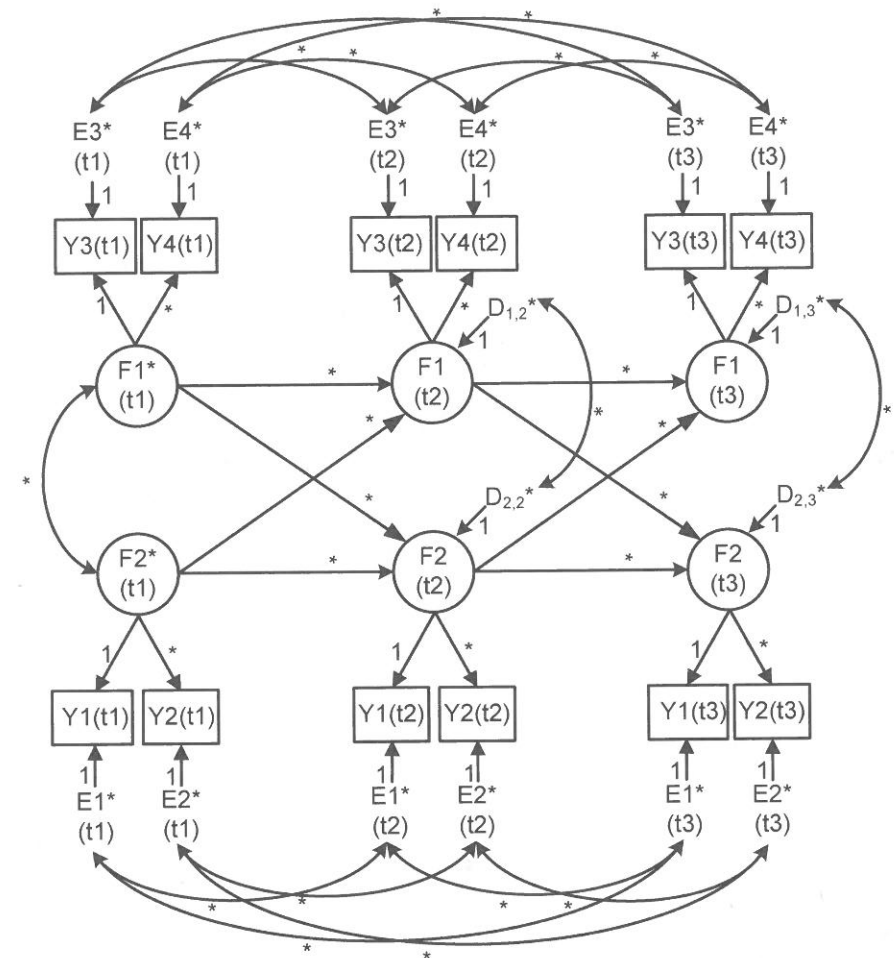


Abbildung 5.1: Ein cross-lagged autoregressives Kausalmodell erster Ordnung mit diachronen Messfehlerkorrelationen

2 Vgl. dazu Biesanz 2012; Sivo 2001; Sivo/Willson 2000.

### ad: Ein-Faktor-Längsschnittmodelle

Die Ein-Faktor-Längsschnittmodelle sind die großen Konkurrenten von Autoregressions-Modellen. Ihre Grundannahme lautet: Jeder Messwert einer Messreihe ist Ausdruck eines einzigen, für den gesamten Beobachtungszeitraum gültigen Faktors plus eines zeitspezifischen Zufallsmessfehlers, der im klassischen Ein-Faktor-Längsschnittmodell nicht mit den Messfehlern von anderen Zeitpunkten korreliert (Sivo/Willson 2000).

Diese Grundannahme bestimmt auch die Grundstruktur eines jeden Ein-Faktor-Längsschnittmodells. In diesen Modellen wird jeder empirische Messwert durch eine frei zu schätzende Faktorladung von dem einzigen Faktor der Zeitreihe bestimmt. Dieser Faktor beeinflusst somit alle Indikatoren der Zeitreihe. Hinzu kommen bei jedem Indikator die Effekte unkorrelierter, zufälliger Indikatoren-Messfehler.

Haben die Ein-Faktor-Längsschnittmodelle mehrere Indikatoren pro Beobachtungszeitpunkt, so mutieren sie zu Faktormodellen höherer Ordnung.

### ad: Modelle zur Analyse von Veränderungsprozessen (Vorher-Nachher-Modelle)

Veränderungsprozesse werden oftmals als Prozesse des sozialen Wandels zwischen zwei Zeitpunkten verstanden. Für die SEM-Analyse eines solchen Veränderungsprozesses stehen typischerweise die Paneldaten des Zeitpunkts t1 (vorher) und des Zeitpunkts t2 (nachher) zur Verfügung, und es wird angenommen, dass der Veränderungsprozess zwischen t1 und t2 stattfindet.

In der Literatur wird darauf hingewiesen, dass sich solche Veränderungsprozesse mit Hilfe von latenten Strukturmodellen in Form von Vorher-Nachher-Modellen besser abbilden lassen als mit Hilfe von Differenzen-Modellen (sog. "change score models" oder "difference score models", a.a.O.: Modelle mit Differenzwerten) oder mit Hilfe von Autoregressionsmodellen, bei denen die Nachher-Variablen als abhängige Variablen bestimmt werden.

Der Vorteil gegenüber autoregressiven Modellen ist dabei, dass die Veränderungsrate selbst als latente Variable geschätzt werden kann. Interessiert also die Veränderungsrate und nicht der Test der Kausalstruktur zwischen latenten Faktoren, dann bieten diese Modelle eine gute Alternative zu den oben vorgestellten Modellen. Zudem eröffnen die Vorher-Nachher-Strukturmodelle eine einfache Möglichkeit, Zusammenhänge zwischen den Veränderungsraten und weiteren Drittvariablen im gleichen Modell zu untersuchen. Sie schließen dabei eine Viel-

zahl von möglichen Fehlerquellen aus, die in anderen Modelle die Ergebnisse verzerren könnten (vgl. Cribbie/Jamieson 2000).

In welcher Weise ein SE-Modell zur Analyse von Veränderungsprozessen spezifiziert werden kann und gleichzeitig Korrelationen des Wandels zu Drittvariablen zu bestimmen sind, zeigt Abbildung 5.2 (nach Cribbie/Jamieson 2000).<sup>3</sup>




Abbildung 5.2: Grundstruktur eines Vorher-Nachher-SE-Modells

#### 5.1.1 Stabilitätskoeffizienten in SEM-Längsschnittanalysen

In vielen SEM-Längsschnittanalysen werden Kovarianzen zwischen den Ausprägungen eines gleichbleibenden Faktors oder Indikators untersucht, der zu unterschiedlichen Zeitpunkten gemessen wurde und dessen Daten in Form von Paneldaten für die Analyse aufbereitet werden. Das gilt z.B. auch für die oben skizzierten Simplex- und Autoregressionsmodelle (a.a.O.).

So können z.B. in einer SEM-Längsschnittanalyse spezielle Pfadbeziehungen zwischen Faktoren, deren Indikatoren zum Zeitpunkt  $t_k$ , zum Zeitpunkt  $t_{k+1}$  und zum Zeitpunkt  $t_{k+2}$  erhoben wurden, berechnet werden. Dann berichten die geschätzten Pfadkoeffizienten (a.a.O.) über die zeitliche Stabilität von interindividuellen Differenzen (s.u.) und dürfen nicht entsprechend des klassischen pfadanalytischen Musters interpretiert werden. In autoregressiven Modellen dürfen die Werte von Pfadkoeffizienten nicht als Maß für die Richtung und Stärke von

<sup>3</sup> Im nachfolgenden Kapitel 5.1.4, in dem es um latente Wachstumskurvenmodelle geht, werden wir eine spezielle Variante dieser Vorher-Nachher-Modelle noch ein wenig genauer betrachten.

Effekten gedeutet werden. Stattdessen müssen diese Pfadkoeffizienten unbedingt als Stabilitätskoeffizienten interpretiert werden. Was bedeutet das?

Stabilitätskoeffizienten berichten nicht über die Stärke und Richtung von Effekten, sondern sie informieren über das Ausmaß von Übereinstimmung zwischen der Rangordnung von Beobachtungsfällen auf einer Variablenkala zum Zeitpunkt  $t_1$  und der Rangordnung der gleichen Beobachtungsfälle zum Zeitpunkt  $t_2$ . Sie berichten mithin über die Konstanz von interindividuellen Differenzmustern im Zeitverlauf. Dies sei an einem Beispiel verdeutlicht (vgl. dazu Abb. 5.3).

Wenn fünf Personen (Gruppe 1) zu einem ersten Beobachtungszeitpunkt ( $t_1$ ) den Einstellungswert "1" aufweisen und weitere fünf Personen (Gruppe 2) zum ersten Beobachtungszeitpunkt ( $t_1$ ) den Einstellungswert "2" aufweisen, und wenn dann zu einem zweiten Beobachtungszeitpunkt ( $t_2$ ) alle Mitglieder von Gruppe 1 einen Einstellungswert von "2" und alle Mitglieder von Gruppe 2 einen Einstellungswert von "3" aufweisen, dann bleibt die Werteordnung zwischen den Mitgliedern innerhalb und außerhalb der Gruppen gleich (vgl. dazu Abb. 5.3a).

In einer SEM-Autoregressionsanalyse ergäbe sich dann ein maximaler Stabilitätskoeffizient von 1.00, denn auch die Abstände zwischen den Werten (und damit die Verteilungsform) hätten sich im Zeitverlauf nicht geändert. Und wenn ein Koordinatensystem aus den  $t_1$ -Werten (X-Variable) und den  $t_2$ -Werten (Y-Variable) gebildet würde, ließe sich der Stabilitätskoeffizient auch als Steigungskoeffizient ( $b = +1.00$ ) derjenigen Geraden verstehen, auf der alle Beobachtungswerte anzusiedeln wären (vgl. dazu Abb. 5.3a).

Ein Stabilitätskoeffizient von 1.00 ergäbe sich aber auch, wenn die Einstellungswerte konstant blieben (vgl. Abb. 5.3d:  $t_1$ : 1/3;  $t_2$ : 1/3) oder wenn sich die Einstellungswerte verkleinerten und dabei die relative Ordnung zwischen den Personen nicht verändert würde sowie gleichzeitig die Verteilungsform nicht variierte (vgl. Abb. 5.3b:  $t_1$ : 3/2;  $t_2$ : 2/1).

Nur wenn sich die Werteordnung in ihr komplettes Gegenteil verkehrte, erbrächte der Stabilitätskoeffizient einen negativen Wert von -1.00 (vgl. Abb. 5.3c:  $t_1$ : 1/3;  $t_2$ : 3/1).

Und wenn es keinerlei Systematik des Übergangs vom ersten zum zweiten Beobachtungszeitpunkt gäbe, sodass z.B. hohe Einstellungswerte sowohl größer oder kleiner oder auch konstant bleiben könnten (vgl. Abb. 5.3e), bewegte sich der Stabilitätskoeffizient gegen null (vgl. dazu Urban 2002).

In der Praxis ist der standardisierte Stabilitätskoeffizient ( $b^*$ ) natürlich immer kleiner als 1.00. Denn es wird bei realen Paneldaten niemals die hier dargestellte Reinform von Veränderungsmustern geben, sondern es wird dort immer eine Mischung aus verschiedenen Veränderungsmustern sowie eine Variation der

relativen Abstände zwischen den Beobachtungsfällen vorliegen. Auch dann gilt jedoch:

Je mehr sich der Stabilitätskoeffizient einem Wert von 0 annähert, umso geringer ist die Stabilität der Werteordnung im analysierten Zeitintervall. Und je mehr sich der standardisierte Stabilitätskoeffizient einem Wert von 1.00 annähert, umso höher ist die Stabilität der Werteordnung im analysierten Zeitintervall.

Abb. 5.3a: Maximale Stabilität bei positivem Wachstum




Abb. 5.3b: Maximale Stabilität bei negativem Wachstum




Abb. 5.3c: Maximale Stabilität bei gegenläufigem Wachstum




Abb. 5.3d: Maximale Stabilität bei Konstanz




Abb. 5.3e: Null-Stabilität bei Konstanz sowie positivem u. negativem Wachstum




Abbildung 5.3: Typen von interindividueller Stabilität (aus: Urban 2002: 14)



Stabilität in der Längsschnittanalyse bedeutet somit entweder a) Konstanz oder b) Veränderung durch Wachstum um einen konstanten Betrag. Eine hohe Stabilität bzw. ein standardisierter Stabilitätskoeffizient nahe 1.00 besagt, dass die Rangordnung der Untersuchungseinheiten (z.B. der befragten Personen) über die Zeit konstant geblieben ist und dass sich gleichzeitig die Verteilungsform der Variablenwerte (bzw. die relativen Rangabstände zwischen den einzelnen Variablenwerten) über die Zeit hinweg nicht bedeutsam verändert hat.

Wird die Analyse von Stabilitätskoeffizienten in SE-Modellen mit Faktorstrukturen (d.h. mit latenten Konstrukten) durchgeführt, so ist zu beachten, dass die Stabilitätskoeffizienten zwischen den zeitspezifischen Faktoren hoch sein können (z.B. um 0.90), obwohl u.U. die Korrelationen zwischen den einzelnen zeitspezifischen Indikatoren gering sind (z.B. um 0.40). Denn einzelne Indikatoren können wenig reliabel sein (wenn sie z.B. durch Messfehler verunreinigt sind), sodass die Korrelationen zwischen diesen Indikatoren nach unten gemindert sind, während die minderungskorrigiert geschätzten Stabilitäten zwischen den dazugehörigen Faktoren erhöht werden (a.a.O.: Minderungskorrektur).

Wenn also nach der Stabilität von Faktoren in SEM-Faktorenmodellen gefragt wird, so wird nach der Stabilität der von Fehlern bereinigten Werte zwischen einzelnen Messzeitpunkten gefragt.

Dabei sind die Fehler, um die bereinigt wird, nicht immer nur Zufallsfehler. Die SEM-Längsschnittanalyse hat den großen Vorteil, dass sie auch systematische Fehler identifizieren und kontrollieren kann. Solche systematischen Fehlerstrukturen können z.B. dadurch entstehen, dass Fehlerterme des gleichen Indikators über die Zeit hinweg miteinander korrelieren. Dementsprechende Korrelationen können z.B. durch stets gleiche Frageformulierungen oder ein anderes, nicht im Modell berücksichtigtes latentes Konstrukt verursacht werden (vgl. Gerbing/Anderson 1984). In der SEM-Längsschnittanalyse können systematische Fehler durch Spezifikation von Modellen mit diachronen Residuenkorrelationen (a.a.O.) oder von Modellen mit selbstständigen Methoden-Faktoren (a.a.O.) kontrolliert werden.

Generell gilt aber für alle SEM-Längsschnittanalysen, in denen spezielle Faktormodelle bzw. Messmodelle verwendet werden, dass in einem ersten Analyseschritt die Zeitreihentauglichkeit dieser Modelle kontrolliert werden muss. Dabei ist es Ziel der Analyse, eine ausreichende "Faktorinvarianz" (a.a.O.) eines jeden Messmodells nachzuweisen. Dazu mehr im Folgenden.

### 5.1.2 Faktorinvarianz in SEM-Längsschnittanalysen/Gruppenvergleichen

Wenn in einer SEM-Längsschnittanalyse die Entwicklung von Faktoren über zwei oder mehr Beobachtungszeitpunkte hinweg verfolgt werden soll, ist in der Analyse sicherzustellen, dass im Beobachtungszeitraum die Faktoren nicht ihre inhaltliche Bedeutung verändern. So darf aus dem Faktor "Umweltbewusstsein", der vor allem durch eine hohe Faktorladung des Indikators "Umweltwissen" bestimmt wird, nicht plötzlich ein Faktor "Umweltbewusstsein" werden, der vor allem durch die Faktorladung des Indikators "umweltbezogene Verhaltensbereitschaft" bestimmt wird.

Ähnliches gilt für den SEM-Vergleich von Subgruppen. Auch bei diesen Analysen sollte davon ausgegangen werden können, dass die inhaltliche Bedeutung von Faktoren in allen untersuchten Subgruppen gleich ist.

In der SEM-Analyse kann die inhaltliche Bedeutung von Faktoren konstant gehalten werden, indem rechentechnisch erzwingen wird (mittels sog. "constraints"), dass sich die Faktorstrukturen trotz wiederholter Messungen nicht wesentlich verändern und somit invariant werden. Denn Längsschnittanalysen (aber auch Gruppenvergleiche), bei denen die gleichen Faktoren mehrfach gemessen werden, erfordern eine Faktorinvarianz der untersuchten Konstrukte. Die Ladungsstruktur in Messmodellen darf sich im Zeitverlauf (oder zwischen Subgruppen) nicht wesentlich verändern, wenn die dazugehörigen Faktoren zum Thema einer Zeitreihenanalyse (oder eines Subgruppenvergleichs) gemacht werden sollen. Die latenten Konstrukte müssen eine robuste zeit- bzw. subgruppenunabhängige Faktorstruktur aufweisen, wobei zur Faktorstruktur die Art und Anzahl der Indikatoren, deren absolute Ladungswerte und auch die relativen Relationen der Faktorladungen untereinander gehören.

Es können mehrere Typen von Faktorinvarianz unterschieden werden. Diese sind unterschiedlich hinsichtlich ihrer Rigidität und hinsichtlich der Modellkomponenten, die von Invarianz betroffen sein sollen.<sup>4</sup>

Ob ein jeweiliger Invarianztyp mit einem spezifischen SE-Modell und den dafür zur Schätzung bereitstehenden Daten kompatibel ist, muss in jedem Fall mittels eines Chi-Quadrat-Differenzentests (a.a.O.) getestet werden. Dabei wird der Fit (a.a.O.) des Modells mit Invarianz-Restriktionen<sup>5</sup> mit dem Fit des gleichen Modells verglichen, bei dem keine Invarianz-Restriktionen festgelegt wurden. Inferenzstatistisch wird dann darüber entschieden, ob die Invarianz-Restriktionen

<sup>4</sup> Vgl. dazu u.a. Raines-Eudy 2000.

<sup>5</sup> Solche Invarianz-Restriktionen können durch Spezifikation von "constraints", d.h. durch Fixierung oder Gleichsetzung von Modellparametern, erreicht werden.